

Sensibilidad al pardeamiento del raquis de uva de mesa

Jhonatan Loayza

Table of contents

Resultados	1
1. Caracterizacion inicial a cosecha	1
2. Relación de acuedo hue inicial, Contenido Relativo del agua	3
3. Almacenamiento comercial en postcosecha.	8

```
# Import librerias necesarias
import pandas as pd
import openpyxl
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import matplotlib.colors as mcolors
from sklearn.metrics import r2_score, mean_squared_error
from sklearn.linear_model import LinearRegression
```

Resultados

1. Caracterizacion inicial a cosecha

```
print('Tabla 1: Caracterizacion inicial en cosecha, cv. Allison y S. Celebreton.(media ± DE)')

Cosecha = pd.read_excel(r'../datos/caracterizacion inicial.xlsx')
df = pd.DataFrame(Cosecha)

df.columns = df.columns.str.strip() # Normalizar nombres de columnas
```

```

# Filtro de datos de acuerdo evaluacion 0h,3h,18h
df_filtrado = df[df["Evaluacion"].isin(["E00", "E03", "E18"])]

# Tabla resumen de caracterizacion inicial
df_resumen =(df_filtrado.groupby('Variedad')
              [['TSS','Acidez_tituable', 'Peso', 'Calibre_Ecuatorial', 'Firmeza']]
              .agg(['mean', 'std','count'])
              .round(2)
              .reset_index()
              )
# creamos un tabal media + DE
tabla_resumen = pd.DataFrame()
tabla_resumen["Variedad"] = df_resumen["Variedad"]

for var in ["TSS", "Acidez_tituable", "Peso", "Calibre_Ecuatorial", "Firmeza"]:
    tabla_resumen[var] = df_resumen.apply(
        lambda x: f"{x[(var, 'mean')]:.2f} ± {x[(var, 'std')]:.2f}", axis=1
    )

# Renombrar encabezados
tabla_resumen = tabla_resumen.rename(columns={
    "TSS": "TSS (°Brix)",
    "Acidez_tituable": "Acidez Titulable (g/L)",
    "Peso": "Peso (g)",
    "Calibre_Ecuatorial": "Calibre (mm)",
    "Firmeza": "Firmeza (gf mm-1)"
})

print(tabla_resumen)

```

Tabla 1: Caracterizacion inicial en cosecha, cv. Allison y S. Celebreton.(media ± DE)

	Variedad	TSS (°Brix)	Acidez Titulable (g/L)	Peso (g)	Calibre (mm)	\
0	AL	19.04 ± 1.04	0.64 ± 0.07	10.18 ± 1.82	22.57 ± 1.58	
1	SC	18.04 ± 0.80	0.78 ± 0.09	9.03 ± 1.61	23.60 ± 1.54	
		Firmeza (gf mm-1)				
0		322.48 ± 64.59				
1		242.69 ± 18.44				

2. Relación de acuedo hue inicial, Contenido Relativo del agua

```
# 1. Cargamos archivos
# =====
datos_correlacion = pd.read_csv(r'../datos/Pardeamiento uva de mesa.csv', sep=';')

df = pd.DataFrame(datos_correlacion)
df.columns = df.columns.str.strip() # Normalizar nombres de columnas

#Visualizar las primeras columnas de df.
#print(df.columns)
#df.info()
#df.head()

# 2. Crear un identificador único por racimo
df['ID'] = (df['Variedad'].astype(str) + '_' +
            df['Productor'].astype(str) + '_' +
            df['Tratamientos'].astype(str) + '_' +
            df['Repeticion'].astype(str) + '_' +
            df['N_Racimo'].astype(str))

# 3. Pivotar para tener columnas separadas
tabla_correlaciones = (
    df.pivot_table(
        index=['Variedad', 'ID'],
        columns='Tiempo',
        values='Hue'
    )
    .reset_index()
    .round(2) # redondear a 2 decimales
)

#Visualizar tabla de correlaciones
#tabla_correlaciones.head()
#tabla_correlaciones.info()
# Colormap personalizado con ayuda de Chatgpt
colors = [
    (0.8, 0.2, 0.1), # Rojo degradado (menos saturado, más natural)
    (1.0, 0.5, 0.0), # Naranja
    (1.0, 1.0, 0.0), # Amarillo
    (0.7, 1.0, 0.3) # Verde amarillento
]
```

```

cmap_rav = mcolors.LinearSegmentedColormap.from_list("rojo_amarillo_verde", colors, N=256)

# 4. Crear figura de correlaciones por variedad hus vs hue
plt.figure(figsize=(9, 5))
variedades = tabla_correlaciones['Variedad'].unique()

# 5. Colores distintos para las líneas
colores_linea = ['black', 'blue']

# Correlaciones del T0 y T10
sc = plt.scatter(tabla_correlaciones['T0'],
                 tabla_correlaciones['T10'],
                 c=tabla_correlaciones['T10'],
                 cmap=cmap_rav
)

# Regresión lineal por variedad
for i, variedad in enumerate(variedades):
    datos = tabla_correlaciones[tabla_correlaciones['Variedad'] == variedad]
    X = datos[['T0']].values
    y = datos['T10'].values

    #Regresion lineal
    modelo = LinearRegression()
    modelo.fit(X, y)
    y_pred = modelo.predict(X)

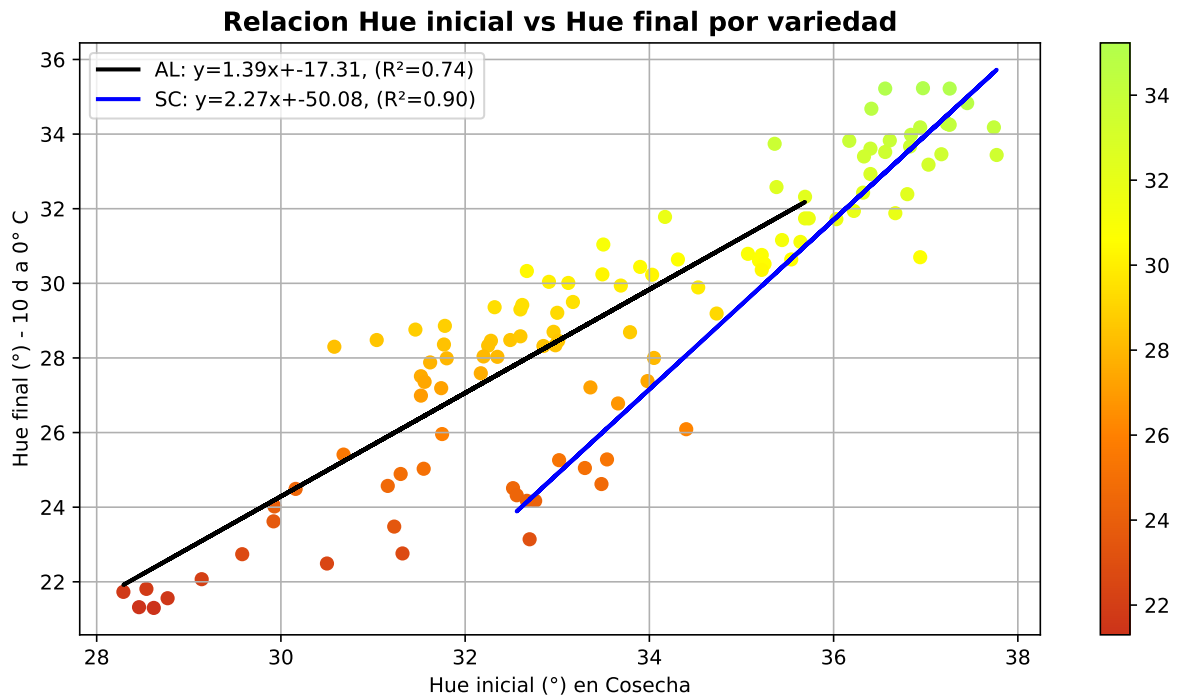
    # Calcular R2, pendiente, intercepto
    r2 = r2_score(y, y_pred)
    pendiente = modelo.coef_[0]
    intercepto = modelo.intercept_

    # Dibujar la línea de regresión variedad
    plt.plot(X, y_pred,
             color=colores_linea[i % len(colores_linea)],
             lw=2, label=f'{variedad}: y={pendiente:.2f}x+{intercepto:.2f}, (R2={r2:.2f})')

# Etiquetas y formato Grafico
plt.xlabel('Hue inicial (°) en Cosecha')
plt.ylabel('Hue final (°) - 10 d a 0° C')
plt.title('Relacion Hue inicial vs Hue final por variedad', fontsize=13, weight='bold')
plt.colorbar()

```

```
plt.grid(True)
plt.legend(frameon=True)
plt.tight_layout()
plt.show()
```



```
# 2 Correlacion de acuerdo CRA vs pardeamiento -----
datos_CRA = pd.read_csv(r'../datos/Contenido relativo de agua.csv', sep=';')

#datos_CRA.info()

#Calculamos el promedio CAR en T0
CRA_promedio_T0 = (
    datos_CRA
    .groupby(['Productor', 'Variedad', 'Color', 'Tratamientos'])['CAR']
    .mean()
    .round(2)
    .reset_index()
)

#Filtrar pardeamiento T10 ---
Pardo_t10 = df[df['Tiempo'] == 'T10']
```

```

#print(Pardo_t10.columns)

#Calculamos en promedio pardeamiento T10

Pardo_promedio_T10 = (
    Pardo_t10
    .groupby(['Productor', 'Variedad', 'Color', 'Tratamientos'])['Pardo']
    .mean()
    .round(2)
    .reset_index()
)

#Unimos ambos promedio por columnas comunes
CAR_VS_PAR = pd.merge(
    CRA_promedio_T0,
    Pardo_promedio_T10,
    on=['Productor', 'Variedad', 'Color', 'Tratamientos']
)

colors = [
    (0.7, 1.0, 0.3), # Verde amarillento
    (1.0, 1.0, 0.0), # Amarillo
    (1.0, 0.5, 0.0), # Naranja
    (0.8, 0.2, 0.1) # Pardo/rojo degradado
]

cmap_rav1 = mcolors.LinearSegmentedColormap.from_list("verde_a_pardo", colors, N=256)

# --- Crear gráfico de correlación CAR vs Pardo ---
plt.figure(figsize=(10, 6))
variedades = CAR_VS_PAR['Variedad'].unique()
colores_linea = ['black', 'blue']

# Dispersión global
sc = plt.scatter(CAR_VS_PAR['CAR'], CAR_VS_PAR['Pardo'], c=CAR_VS_PAR['Pardo'], cmap= cmap_rav1)

# Regresión lineal por variedad
for i, variedad in enumerate(variedades):
    datos = CAR_VS_PAR[CAR_VS_PAR['Variedad'] == variedad]
    X = datos[['CAR']].values
    y = datos['Pardo'].values

    modelo = LinearRegression()

```

```

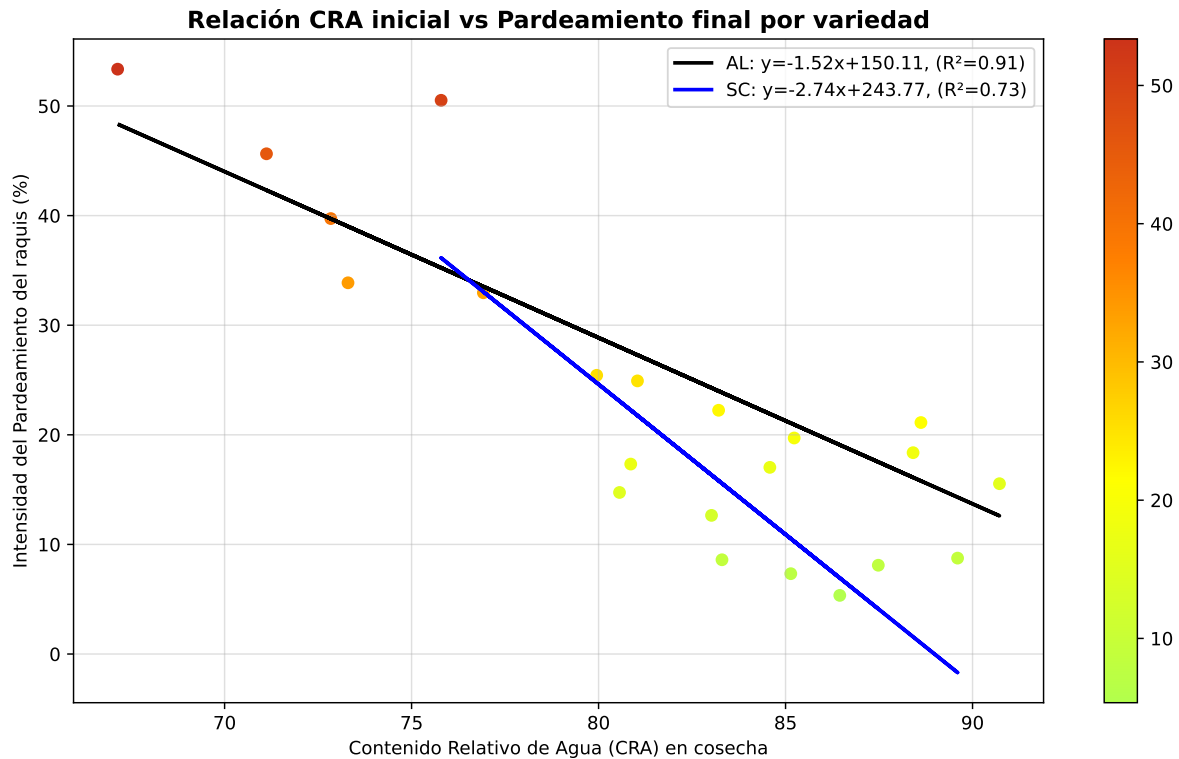
modelo.fit(X, y)
y_pred = modelo.predict(X)

r2 = r2_score(y, y_pred)
pendiente = modelo.coef_[0]
intercepto = modelo.intercept_

plt.plot(X, y_pred,
         color=colores_linea[i % len(colores_linea)],
         lw=2,
         label=f'{variedad}: y={pendiente:.2f}x+{intercepto:.2f}, (R²={r2:.2f})')

# --- Formato final ---
plt.xlabel('Contenido Relativo de Agua (CRA) en cosecha')
plt.ylabel('Intensidad del Pardeamiento del raquis (%)')
plt.title('Relación CRA inicial vs Pardeamiento final por variedad', fontsize=13, weight='bold')
plt.colorbar()
plt.grid(alpha=0.4)
plt.legend(frameon=True)
plt.tight_layout()
plt.show()

```



3. Almacenamiento comercial en postcosecha.

Revisara si las variables de acuerdo el color en cosecha influyen en el pardeamiento del raquis de uva de mesa de amabas variedades.

```
# 1. Cargar datos
# =====

df = pd.read_csv(r'../datos/Almacenamiento comercial.csv', sep= ';')
df.columns = df.columns.str.strip()

# 2. Opcional: ordenar niveles de Tiempo si quieres
orden_tiempo = ['T40', 'T43']

if set(orden_tiempo).issuperset(df['Tiempo'].unique()):
    df['Tiempo'] = pd.Categorical(df['Tiempo'], categories=orden_tiempo, ordered=True)
```

```

# 3. Crear boxplot facetado por Variedad
colores = {'A': "#f2f464",
           'V': "#29ac29"}

g = sns.catplot(
    data=df,
    kind='box',
    x='Tiempo',
    y='Pardo',
    hue='Color',
    col='Variedad',
    palette=colores,
    height=5,
    aspect=1,
    fliersize=4,          # tamaño de outliers
    linewidth=1.2
)

# Ajusta leyenda fuera del grafico
g._legend.set_bbox_to_anchor((1.12, 0.5))

# =====
# 4. Ajustes finales - Escala Y fija

for ax in g.axes.flatten():
    ax.set_ylim(0, 100) # ← AQUÍ SE FIJA LA ESCALA DE 0 A 100
    ax.set_ylabel("% Área parda del raquis", fontsize=11)
    ax.set_xlabel("Tiempo de almacenamiento (días)", fontsize=11)
    ax.tick_params(axis='both', labelsize=10)
# =====
# 5. Títulos y estética final

g.fig.suptitle(
    " Pardeamiento del raquis durante el almacenamiento comercial poscosecha",
    y=1.05,
    fontsize=14,
    fontweight='bold'
)

for ax in g.axes.flatten():
    ax.set_ylabel("% Área parda del raquis", fontsize=11)
    ax.set_xlabel("Tiempo de almacenamiento (días)", fontsize=11)

```

```
ax.tick_params(axis='both', labelsz=10)

plt.tight_layout()
plt.show()
```

